

Introduction à la statistique spatiale

SAINTILAN Brandon

ENSAI 2A

2025-2026

Objectifs du cours

- Sensibiliser à l'importance de la dimension spatiale
- Introduction aux cours de 3A : « Econométrie spatiale », « Analyse spatiale », « Statistiques et économétrie spatiales »
- **Savoir manipuler des données spatiales**
- **S'initier à la cartographie (QGIS et R)**

Plan du cours

- I) Introduction : Pourquoi s'intéresser à la dimension spatiale en statistiques?
- II) Les types de données spatiales
- III) La carte comme outil de représentation
- IV) Le problème du MAUP
- V) L'autocorrélation spatiale
- VI) Cartographie avec QGIS (en TP)
- VII) Sémiologie et types de cartes (en TP)

Evaluation

- Un exercice à faire à la maison (donné au début du **TP2 du 12 février**, à rendre avant le **dimanche 22 février au soir 23h45**)
- Une évaluation papier (quizz/questions sur le cours : **15', TP4 le 12 mars**)
- Un TP noté de **2 heures** (dernier TP : **TP6 du 3 avril**)

- **"Manuel d'analyse spatiale - Théorie et mise en oeuvre pratique avec R", INSEE METHODES N°131, octobre 2018.**
- De Bellefon M-P., "Introduction à l'analyse spatiale", Séminaire de Méthodologie Statistique, 5 juillet 2016
- Brunsdon C., Comber L., "R for spatial analysis and mapping", SAGE, 2019
- Lambert N., Zanin C., "Manuel de cartographie", ARMAND COLIN, 2016
- LAURENT T., "Statistique spatiale avec R", Séminaire ODR, 4 septembre 2018.

Documentation (quelques sites web)

- http://sergelhomme.fr/doc/Statistique_Spatiale.pdf
- https://rcarto.github.io/carto_avec_r/chapitre1.html
- <https://www.book.utilitr.org/spatdata.html>
- <https://rgeomatic.hypotheses.org/>
- http://math.agrocampus-ouest.fr/infoglueDeliverLive/digitalAssets/92746_Visu3D.pdf
- Manuel de QGIS :
 - [Débutant](#)
 - [Complet](#)
- ET SURTOUT : GOOGLE DE MANIÈRE GÉNÉRALE!

I. Introduction

- Selon vous, dans quels sujets d'études tenir compte de la localisation est important ?

I. Introduction

- On aurait envie de dire dans (presque) tout !

I. Introduction

- Dans l'immobilier : le prix d'un logement est fortement lié à son environnement. On ne peut se reposer sur des critères objectifs simples, tels que le nombre de pièces, la superficie du logement, la présence d'un garage, etc...
- Un tel modèle supposerait que les prix des biens seraient homogènes sur l'ensemble du territoire, dès lors que les caractéristiques du logement sont équivalentes.
- C'est évidemment faux en raisonnant à l'échelle de la France, ça l'est également à l'échelle de la commune (exemple de la carte scolaire). Le système d'affectation des élèves du public en fonction de leur domicile).

I. Introduction

- **Dans le domaine économique :** les villes, régions, pays et entreprises interagissent : concurrence spatiale, diffusion de pratiques, concentration d'activités (exemple : **centres commerciaux**) et spécialisation économique (exemple de Toulouse et de l'aéronautique).

Les 10 principaux partenaires commerciaux de la France en 2020 (source : DGDDI)

Total volume d'échanges*	
Allemagne	131 912 456
Chine	73 951 754
Italie	71 290 351
Espagne	66 073 339
États-Unis	63 482 771
Belgique	63 242 018
Royaume-Uni	43 926 351
Pays-Bas	38 638 028
Suisse	27 211 932
Pologne	20 537 640

* En millions d'euros


I. Introduction

- **En sociologie** : étude de la ségrégation spatiale, des quartiers avec des taux de pauvreté très importants (crise des banlieues en 2005).




I. Introduction

- Dans le domaine environnemental : étude de la pollution




I. Introduction

- **Délinquance** : les **cambrjolages de logement** (nb d'infractions pour 1 000 hab) en 2024 par commune de commission (zoom sur la Bretagne)



■ Délinquance/sentiment d'insécurité :

Figure 6 – Sentiment d'insécurité dans le quartier ou le village en 2022



Lecture : En 2022, l'Aisne fait partie des départements dans lesquels une part plus importante de la population que dans les autres départements déclare se sentir en insécurité dans son quartier ou son village au cours des 12 derniers mois.

Champ : Personnes âgées de 18 ans et plus vivant en logement ordinaire en France métropolitaine, Martinique, Guadeloupe ou à La Réunion.


Source : SSMSI, enquête Vécu et ressenti en matière de sécurité (VRS) 2022 (questionnaire socle, internet) ; traitement SSMSI.

I. Introduction

95 % de la population vit à moins de 14 minutes d'un lieu d'accueil de la police ou de la gendarmerie nationales

■ Accès aux services de sécurité :

Figure 10 – Temps d'accès aux commissariats de police et brigades de gendarmerie en France métropolitaine



Note : Carte des temps d'accès lissés sur un rayon de 8 km pour chaque carreau de 1 kilomètre de côté.

Lecture : En 2022, une grande partie du territoire national est située à moins de 15 minutes en voiture d'un commissariat de police ou d'une brigade de gendarmerie. Dans les massifs montagneux français, les trajets peuvent être supérieurs à 30 minutes.

Champ : France métropolitaine.

Source : Ministère de l'Intérieur – Liste des services de police et de gendarmerie nationales accueillant du public avec géolocalisation, 2022 ; Insee – distancier Metric-OSRM ; IGN – contours géographiques ; © les contributeurs d'[OpenStreetMap](#) et du projet [OSRM](#).

I. Introduction

- **Dans les données routières** : étude du trafic (accidents, bouchons...etc)
- **En sondage** : quelle conclusion tirer sur la population de Bruz, si le recensement de la population est fait uniquement sur le campus de Ker Lann ?
- ...

I. Introduction

Conséquences du point de vue du statisticien :

- En modélisation, beaucoup d'hypothèses ne sont plus valides sous l'effet d'un phénomène spatial (exemple: observations iid).
- Si le modèle ne tient pas compte d'une variable spatialement corrélée à notre variable d'intérêt, il y a un biais de variable omise.
- En cas de phénomène spatial, les résidus peuvent être corrélés. Dit autrement, on va observer une dépendance entre des observations proche. La non prise en compte de la dimension spatiale va alors biaiser nos estimateurs.
- En cas de phénomène spatial, les effets peuvent être différenciés : on parle d'hétérogénéité spatiale. La direction et l'amplitude des effets n'est pas la même partout.

I. Introduction

- La localisation des observations va avoir une influence sur les valeurs de la variable d'étude, et potentiellement sur les autres valeurs prises par les autres variables.

Définition :

- La statistique spatiale étudie des phénomènes observés sur un ensemble spatial S . Elle vise notamment à **identifier la structure spatiale des observations et quantifier la force des interactions spatiales.**

Un principe :

- **Loi de Tobler** : "Tout interagit avec tout, mais deux objets proches ont plus de chance de le faire que deux objets éloignés "


I. Introduction

- La localisation et la valeur de la variable vont donc s'étudier conjointement. Observer $X(s)$, c'est autre chose que d'observer d'un côté X et de l'autre s . Tout comme séries temporelles, on n'étudie pas X et t séparément mais $X(t)$. En statistique spatiale, s désigne le couple de coordonnées (x,y) .

Un indicateur : l'autocorrélation

- En séries temporelles, on voit que $X(t)$ influence $X(t+h)$. On peut appliquer ce raisonnement à des données spatiales.

fonction d'autocorrélation d'une série temporelle



I. Introduction

- Ce principe d'autocorrélation va être à le point de départ de toute étude impliquant de la dépendance spatiale (un peu comme le seraient des statistiques descriptives avant toute modélisation). Pour identifier un phénomène d'autocorrélation spatiale, il y a plusieurs questions à se poser, notamment :
- Sur quel type de données est-ce que je travaille (Chapitre 2)?
- Comment représenter mes données et à quelle échelle (Chapitre 3)
- Quel problème mon découpage ou mon échelle d'étude soulève ? (Chapitre 4)
- Comment définir mon voisinage (Chapitre 5)?

CHAPITRE 2 : Les types de données spatiales

II. Les types de données spatiales

- « Une donnée spatiale est une observation dont on connaît non seulement la valeur, mais aussi la localisation. Le support des observations, défini comme l'ensemble des coordonnées spatiales des objets à traiter, constitue une **information potentiellement riche pour l'analyse.** »
- On parle aussi de **géométrie** associée à une donnée spatiale pour **caractériser sa localisation ou son contour.** Les données spatiales sont des objets géométriques tels que des **points, des lignes, des polygones, ou des maillages (raster).** Les objets géométriques sont décrits à d'un système de coordonnées qui permettent la représentation dans un espace euclidien $((x,y))$.
- Les coordonnées d'une donnée spatiale dépendent du système de projection. Le **système de projection permet le passage de la Terre (sphère) à une représentation sous forme de plan.**
- On parle aussi **d'attribut** pour caractériser la valeur associée à une donnée spatiale (population, taux de chômage, etc...)

II. Les types de données spatiales

- On peut distinguer 3 types de données spatiales :
 - A) Les données ponctuelles
 - B) Les données continues
 - C) Les données surfaciques


II.A Les données ponctuelles

- Dans le cas de données ponctuelles, **on s'intéresse uniquement à la localisation des observations et non pas à leur valeur.**
- Les données spatiales ponctuelles se caractérisent par la **distribution dans l'espace des observations.**
- **Seul compte la localisation. Cela va être le cas, lorsque l'on étudie l'apparition d'une maladie par exemple.**
 - On va chercher à **regarder si l'apparition d'un phénomène se fait de manière concentrée à certains endroits (cas de clusters)**
 - Ou si le phénomène est très diffus, comme ce serait le cas avec une distribution aléatoire

-> L'analyse spatiale **sur données ponctuelles** va donc consister à **comparer la distribution de la localisation de nos observations avec une distribution aléatoire.**


II.A Les données ponctuelles

- Exemple de l'épidémie de Cholera à Londres : John Snow avait cartographié les lieux de survenue de l'épidémie dans le quartier de Soho (quartier très insalubre) -> naissance de l'épidémiologie.



II.A Les données ponctuelles

- Autre exemple : détection de clusters de maisons de mauvaise qualité (Fotheringham et al., 1996). La comparaison avec une distribution aléatoire dans l'espace permet ensuite d'évaluer la significativité.



II.A Les données ponctuelles

■ Autre exemple :

Figure 2 – Répartition des commissariats de police et des brigades de gendarmerie en France métropolitaine en 2022

- Les commissariats sont essentiellement concentrés dans les grandes métropoles et dans les chefs-lieux des départements
- Les brigades de gendarmerie sont elles principalement dispersées sur le territoire
- 2 908 brigades GN, 4 fois plus que de commissariats PN, mais la population est divisée à parts égales entre les 2 institutions.

En effet, 50 % des habitants de la métropole sont concentrés dans moins de 1 700 communes, là où 720 commissariats PN sont implantés. L'autre moitié est répartie dans plus de 33 100 communes (= ZGN) couvrant ainsi 95 % du territoire métropolitain.




Champ : France métropolitaine.

Sources : Chenu B., « 95 % de la population vit à moins de 14 minutes d'un lieu d'accueil de la police ou de la gendarmerie nationales », Interstats Analyse n° 61, juin 2023.


II.A Les données ponctuelles

- Dernier exemple : Etude de la localisation de quatre types de services dans la ville de Rennes. L'étude des équipements se fait souvent à partir de données ponctuelles.

Ecoles




Pharmacies



Magasins de vêtements



Médecins



II.A Les données ponctuelles

- En résumé, lorsqu'on étudie des données ponctuelles, on étudie des points géolocalisés (on parle aussi de « semis de points »).
- Les méthodes pour les étudier sont des méthodes de configuration de points qui reposent sur la statistique inférentielle. Plus exactement, on utilise les processus ponctuel aléatoires. On va générer une infinité de réalisations de même loi.
- Ces méthodes s'appliquent à des objets dont on observe qu'une seule réalisation (une seule répartition). Par exemple : la répartition des médecins dans une commune, la répartition des commerces, etc...

II.B Les données continues



- A la différence des données ponctuelles, dans le cas de données continues, il y a la **présence d'une valeur en tout point du territoire.**
- **Ce n'est donc pas la localisation qui nous intéresse** puisqu'il y a une réalisation partout. **C'est la valeur de ma variable d'intérêt qui sera le critère d'étude.** Cela va être par exemple des études sur la pollution (la qualité de l'air est en théorie mesurable en tout point), la qualité de l'eau de la mer, la présence d'un composant chimique dans le sol, la météorologie etc...

II.B Les données continues

- Cependant, si les valeurs sont mesurables **théoriquement** en tout point, ce n'est pas ce qui se passe dans la réalité (budget des capteurs, espace, ... etc). Les **données sont issus d'échantillons** : on va collecter des relevés en certains points.
- Lorsqu'on travaille sur données ponctuelles, le but est généralement de **prédire les valeurs prises par notre variable aux endroits non échantillonnés**. **C'est ce qu'on appelle la « géostatistique »**. Au-delà des prédictions en elles-mêmes, on va également **faire des tests** (étude de la fiabilité des résultats) mais aussi **réfléchir à l'échantillonnage** (où faire les relevés).
- Une des méthodes fréquemment utilisée en géostatistique est le **krigeage** qui vise à faire de l'interpolation (prédiction) à partir des données observées, **en étudiant la corrélation spatiale des observations**.

II.B Les données continues

- Exemple : Prédiction de la teneur en polluant d'un sol (mg/kg/m²) (à gauche) et écart-type de la prédiction (à droite). Source : Manuel GéoSiPol - Mines de Paris : CHILES et al. 2005



II.C Les données surfaciques


- Dans le cas de données surfaciques, on s'intéresse à la **valeur prise par une variable d'intérêt sur un territoire délimité.**
- Cela va donner lieu généralement à une **partition du territoire (zones)** pour lesquelles on va **étudier les relations existantes entre zones voisines.**
- Chaque zone du territoire est associée à une **localisation fixe** et unique ainsi qu'à une **valeur prise par notre variable d'intérêt** (PIB par région, taux de chômage départemental, etc...).

II.C Les données surfaciques

- Dans le cas de données surfaciques, la **notion de voisinage est importante** : comment considérer qu'un territoire est **voisin ou non**.
- On va ensuite essayer de **quantifier l'influence des voisins sur notre variable d'intérêt**.
- Pour décrire les relations entre voisins, on pourra utiliser les **méthodes d'indices d'autocorrélation spatiale**.

II.C Les données surfaciques

- Exemple : Taux de chômage départemental au T2 2025 (Source Insee)



(p) Les données du dernier trimestre sont provisoires.

Champ : France hors Mayotte.

Source : Insee, estimations de taux de chômage localisés et taux de chômage au sens du BIT.

Conclusion du chapitre II

- De la nature des données va dépendre le choix de la méthode à utiliser.
- Le type de données n'est pas toujours bien identifié. Cela va dépendre des questions qu'on se pose. Par exemple :
 - Si l'on étudie la localisation des maisons au sein d'une commune pour identifier des quartiers résidentiels, il s'agira de données ponctuelles.
 - Si l'on prend maintenant comme observations des maisons pour étudier l'âge moyen des propriétaires, cela sera des données surfaciques.
- **Un trait commun à tous ces types de données : ils mobilisent tous l'outil cartographique.**

CHAPITRE 3 : La carte comme représentation

III La carte comme représentation

SOMMAIRE

- A) Pourquoi faire des cartes ?
- B) Le choix de l'échelle d'étude

III.A.1 L'utilité des cartes

- Visualiser des données
- Mettre en évidence des phénomènes spatiaux et des interrelations
- Effectuer des comparaisons (dans le temps ou entre diverses variables)

III.A.2 La carte vision du monde

- Une carte est le résultat d'opérations conscientes et inconscientes (consensus social).

Conscientes :

- Choix du phénomène cartographié
- Choix du titre de la carte


Inconscientes :

- Règles sémiologiques (couleurs chaudes en opposition aux couleurs froides)
- Système de projection usuel (orientation Nord-Sud). (Le passage d'une représentation de la Terre (qui est une sphère) à une représentation sous forme de plan se fait grâce au système de projection)
- Attention : <https://thetruesize.com>




III.A.3 La carte : outil de compréhension et de communication

- La carte est une représentation conventionnelle
- Le choix des couleurs, des objets doit être adapté à la culture du destinataire de la carte.
- Exemple : l'artificialisation des sols en Corrèze. On comprend bien sans avoir à lire la légende.




III.B. Le choix de l'échelle d'étude

- Les cartes n'auront pas du tout les mêmes messages selon l'échelle d'étude choisie.
- Une échelle trop grande peut cacher de grandes disparités au sein des territoires.
- Il faut donc bien se poser la question de ce que l'on cherche à montrer, et surtout de l'échelle à laquelle raisonner.
- Exemples sur le revenu médian en France métropolitaine en 2012 (source : Insee, Filosofi)
→ ici, à l'échelle de la région ...




III.B. Le choix de l'échelle d'étude

- ... ici, à l'échelle du département...



III.B. Le choix de l'échelle d'étude



■ ... à l'échelle de l'arrondissement...



III.B. Le choix de l'échelle d'étude

■ ... puis enfin, à l'échelle de l'IRIS...

- IRIS (Ilot de Regroupement pour l'Information Statistique) : découpage statistique en « quartiers » d'environ 2000 habitants. S'appliquent à toutes les communes de 10000 hab. et plus (et à la plupart des communes de 5000 hab.)
- Volonté avec les acteurs locaux de faire un découpage homogène.
- Découpage présent sur tout le territoire (Si commune non découpée en IRIS, commune=IRIS)



III.B. Le choix de l'échelle d'étude

- Le problème d'échelle s'insère dans un problème plus global (le MAUP)

CHAPITRE 4 : Le problème du MAUP

IV. Le problème du MAUP

MAUP : Modifiable Areal Unit Problem

- Fait référence à 2 problèmes :
- **Problème de l'échelle d'étude.**
 - Les relations entre les phénomènes **changent selon l'échelle d'observation**. Un phénomène ne sera pas bien observé suivant l'échelle (zoomer ou non?). **Agrégation = perte d'information**
 - Parfois pas le choix : pas de données à une maille fine
- **Problème de zonage : découpage spatial (mailles administratives) pas forcément adapté.**
 - Pas homogène : plus petite commune France Metro : Castelmoron-d'Albret (0,04 km²), plus grande : Arles (759 km²)...
 - L'amplitude spatiale d'un phénomène correspond rarement aux frontières administratives...

IV. Le problème du MAUP

- Exemple tiré du manuel d'analyse spatiale (Insee Méthodes)

500	100	700
200	400	100
300	600	200

population

25	40	100
100	80	6
30	150	85

population pauvre


population et
population pauvre
dans 9 unités
géographiques

5%	40%	14%
50%	20%	6%
10%	25%	43%


taux de pauvreté avec 2 échelles différentes

13%
27%
24%

**MAUP : Effet
d'échelle**



taux de pauvreté avec 2 zonages différents



**MAUP : Effet de
zonage**



IV. Le problème du MAUP

Illustration des 2 problèmes (revenus médians à Paris) :

IRIS




Arrondissements




IV. Le problème du MAUP

Indices locaux différents selon l'échelle



Arrondissements




échelle d'agrégation	I_W	p value	H0
Iris	0.68	3.10^{-6}	rejetée
Arrondissement	0.51	$< 9.10^{-9}$	rejetée

H_0 : Les voisins ne **co-varient** pas d'une façon particulière.
 $I_W > 0 \Rightarrow$ autocorrélation spatiale positive.



IV. Le problème du MAUP

Une **solution : le carreau** (ou données carroyées)

- Un zonage simple, donc potentiellement universel
 - Simple à construire
 - Simple à comprendre : **précision géographique constante**
- Un outil d'analyse **impartial**
- Un **zonage unique dans le temps**
- A l'Insee, 2 types de carreaux
 - **200m**
 - **1km**



IV. Le problème du MAUP



<https://www.insee.fr/fr/outil-interactif/7737357/map.html>

IV. Le problème du MAUP

Mais soulève un **autre problème : le secret statistique**

- Une règle : un carreau doit contenir **au moins x ménages** (11 ménages actuellement pour Filosofi).
- Découpage très fin qui permettrait d'avoir des informations sur les individus. Peut nécessiter :
 - **d'agréger des carreaux** (passage au rectangle ou à de plus gros carreaux, exemples : méthode quadtree, chemin du plus court voyageur)
 - de modifier nos données (exemple : la **winsorisation**)

IV. Le problème du MAUP


La winsorisation ?

- « La winsorisation est une technique statistique de traitement des **valeurs extrêmes** d'une distribution, qui **consiste à ramener à un seuil donné toutes les valeurs situées au-delà**, ou en deçà, de ce seuil. »
- Exemples de seuils : les centiles (5% et 95%).
 - Dans le dep35 pour le niveau de vie/UC: $C_{05} = 9\,638,1\text{ €}$, $C_{95} = 42\,744,8\text{ €}$
 - Si niveau de vie carreau $< 9\,638,1\text{ €}$, sera renseigné $9\,638,1\text{ €}$.

IV. Le problème du MAUP

1 Niveau de vie winsorisé des individus, y compris valeurs modifiées (au carreau) (€ par individu) 2015

ACT



IV. Le problème du MAUP

- Utilisation des données carroyées : **politique de la ville** en particulier
- Limites :
 - **secret statistique**
 - peu de données -> **difficile de croiser avec d'autres variables sans imputation** (= perte d'infos)

IV. Le problème du MAUP

Autre solution que le carroyage : le **lissage spatial**

Le lissage a deux types d'utilisation : estimation d'intensité (données ponctuelles) et représentation cartographique simplifiée (données à valeurs ou données pondérées)

Le lissage spatial dans le cas de données pondérées (non ponctuelles) consiste à **estimer la valeur d'un point en effectuant une moyenne pondérée à partir des valeurs voisines**. En principe, plus un point est proche du point d'estimation et plus son poids est important.

On va ainsi avoir des **valeurs lissées** (analogie des moyennes mobiles en séries temporelles). Le but est de filtrer l'information pour faire apparaître les structures sous-jacentes du phénomène étudié.

Plusieurs méthodes pour définir les poids des voisins. Généralement, on utilise des **fonctions de type noyau**. Un noyau est une fonction de densité de probabilité symétrique et positive.


IV. Le problème du MAUP

Exemples : K^N et K^B désignent respectivement un noyau gaussien et un noyau quadratique (aussi appelé Biweight) avec x la distance au point d'estimation et **h** le **paramètre de « bande passante »** (aussi appelé « rayon de lissage »).

$$K_h^N(x) = \frac{1}{2\pi} e^{-\|x/h\|^2}$$

$$K_h^B(x) = \frac{9}{16} 1_{\|x\| < h} \left(1 - \left\|\frac{x}{h}\right\|^2\right)^2$$


Illustration du noyau quadratique biweight. Attention dans le schéma x fait référence au point d'estimation, x_i désigne un point voisin :




Source : manuel d'analyse spatiale

IV. Le problème du MAUP


Le choix du noyau ne joue pas un rôle important. En revanche, le **paramètre de bande passante / rayon de lissage est une question sensible !** Il reflète le **compromis biais-variance** de notre estimation.



r=200m



r=400m



r=1000m

r élevé = variance faible (densité très lissée) / biais élevé

r petit = variance élevée/biais faible

Source : manuel d'analyse spatiale

IV. Le problème du MAUP

Il existe des méthodes pour essayer de déterminer le meilleur rayon de lissage : **maximum de vraisemblance avec validation croisée** par exemple. Voir le manuel pour + de précisions (hors programme)

Le choix du rayon de lissage dépend aussi de ce que l'on étudie.

IV. Le problème du MAUP

Ouverture

- De manière générale, la question s'est posée du choix du découpage/ de l'échelle selon quel problème ?
- En parallèle, prise en compte de la dimension réseau/flux entre les entités géographiques (interconnexions des villes, développement des migrations pendulaires, migrations résidentielles, ...). D'un point de vue théorique : développement de la théorie des graphes en analyse urbaine.

-> Naissance des zonages pour les problématiques locales

IV. Le problème du MAUP

Ouverture

Petit éventail des zonages :

- Aires d'attraction des villes (AAV, anciennement aires urbaines) : attraction d'un territoire au regard de la densité et de l'emploi.
- Les bassins de vie : accès aux équipements/services
- Zone d'emploi : l'emploi!
- Unité urbaine : continuité du bâti

CHAPITRE 5 : L'autocorrélation spatiale

Ce chapitre s'appuie essentiellement sur le manuel d'analyse spatiale de l'Insee. N'hésitez-pas à vous y reporter pour approfondissement.

V. L'autocorrélation spatiale

Rappels sur les types de données


- Il existe 3 type de données spatiales :
 - A) Les **données ponctuelles** : on s'intéresse à la localisation d'observations (non présentes partout) et à comment ces apparitions se répartissent sur le territoire (ex: maladies, équipements, ..)
 - > Méthodes : comparaison avec distribution aléatoire
 - > Relation entre observations : distance
 - B) Les **données continues** : il s'agit de données qui théoriquement existent en tout point du territoire. On s'intéresse à la valeur de l'observation et non pas à sa localisation en tant que tel (ex: pollution, météorologie,...).
 - > méthodes de géostatistique (krigeage)
 - > Relation entre observations : distance
 - C) Les **données surfaciques** : « De toute façon, l'important c'est les valeurs ! »
 - > Méthodes : indices d'autocorrélation, modèles économétriques
 - > Relations : voisinage, distance
- Ce sont les données surfaciques qui vont ici nous intéresser!**

V. L'autocorrélation spatiale

- Dans le cas de données surfaciques, une grande importance va être donnée à la définition du **voisinage**.
- Le voisinage fait référence à une **frontière**. On parle d'objets adjacents lorsque ces objets partagent une même frontière. Cette frontière peut-être réelle (administrative, naturelle, ...) mais aussi **construite (Voronoi)**. Le voisinage n'est qu'un exemple de relation pouvant exister entre 2 objets spatiaux.
- Les relations spatiales $\mathfrak{B}$ sont un sous-ensemble du produit cartésien $\mathbb{R}^2 \times \mathbb{R}^2 = \{(i, j) : i \in \mathbb{R}^2, j \in \mathbb{R}^2\}$ des couples (i, j) d'objets spatiaux, c'est-à-dire l'ensemble des couples (i, j) tels que i et j soient tous deux des objets spatiaux identifiés par leurs coordonnées géographiques, et que (i, j) soit différent de (j, i) .
- **Un objet spatial ne peut pas être relié à lui-même : $(i, i) \notin \mathfrak{B}$** . De plus si $(i, j) \in \mathfrak{B}$ et $(j, i) \in \mathfrak{B}$ pour tout couple d'objets spatiaux, les relations spatiales sont dites symétriques

V. L'autocorrélation spatiale


Schéma général (tiré de Tiefelsdorf)



V. L'autocorrélation spatiale

- Une fois le graphe de voisinage défini et codifié sous forme d'une liste de voisins, on transforme la liaison entre les points i et j en l'élément w_{ij} de la **matrice de poids $\mathbf{W}$** . La matrice de poids $\mathbf{W}$ est "l'expression formelle de la dépendance spatiale entre observations" (Anselin)
- Le plus couramment, la matrice de poids est une matrice de contiguïté binaire :

$$w_{ij} = \begin{cases} 1 & \text{si } i \text{ et } j \text{ sont reliés dans l'espace} \\ 0 & \text{sinon} \end{cases}$$



Contiguïté ROOK

	a	b	c	d	e	Somme des poids des voisins
a	0	1	1	0	0	2
b	1	0	0	1	0	2
c	1	0	0	1	0	2
d	0	1	1	0	1	3
e	0	0	0	1	0	1

Contiguïté QUEEN

	a	b	c	d	e	Somme des poids des voisins
a	0	1	1	1	0	3
b	1	0	1	1	1	4
c	1	1	0	1	0	3
d	1	1	1	0	1	4
e	0	1	0	1	0	2

V. L'autocorrélation spatiale

- Les matrices de poids peuvent également **tenir compte de la distance entre les zones géographiques**, les relations devenant plus faibles avec la distance :

1 si $d < d_0$, $\frac{1}{d^\alpha}$, ou $e^{-\alpha d}$ avec α un paramètre estimé ou défini a priori.

- Utiliser une **distance maximale au-delà de laquelle $w_{ij} = 0$** permet de limiter le nombre d'éléments non nuls.

- Enfin, certaines matrices tiennent compte de la force des relations entre les zones. Le poids peut par exemple être défini par $\frac{b_{ij}^\alpha}{d_{ij}^\alpha}$ avec

b_{ij} une mesure de la force des relations entre les zones i et j (qui n'est pas forcément symétrique), telle que le pourcentage de frontières communes, la population totale, la richesse...

et d_{ij} la distance entre les zones.

V. L'autocorrélation spatiale

- La somme des poids des voisins d'une zone est appelée son degré de **liaison**. Si on ne normalise pas la matrice de poids, ce degré de liaison dépend du nombre de ses voisins, ce qui crée une hétérogénéité entre les zones.
- On va donc faire en sorte que $\sum_{j=1}^n w_{ij}=1$ en divisant les poids par la somme des poids des voisins (**normalisation de W**).
- Chaque poids w_{ij} peut être interprété comme la fraction de l'influence spatiale subie par l'observation i imputable à j .



V. L'autocorrélation spatiale

- **Définition de l'autocorrélation spatiale** : corrélation positive ou négative d'une variable avec soi-même du fait de la localisation des observations.
- Cause : processus inobservés ou difficilement quantifiable :
 - Interaction dans les décisions d'agents (ex : tendance à se regrouper)
 - Diffusion dans l'espace d'un phénomène/technologie
- Intérêt : Travail nécessaire pour s'assurer qu'un modèle est bien spécifié (hypothèses non valides sinon). Aide à comprendre un phénomène
- Les applications : Nombreuses surtout lorsqu'on étudie un phénomène à une échelle locale, le risque d'avoir un phénomène spatial est fort.

V. L'autocorrélation spatiale

- En présence d'autocorrélation spatiale, on observe que **la valeur d'une variable pour une observation est liée aux valeurs de cette même variable pour les observations voisines.**
- L'autocorrélation spatiale est **positive** lorsque des **valeurs similaires** de la variable à étudier **se regroupent géographiquement.**
- L'autocorrélation spatiale est **négative** lorsque des **valeurs dissemblables** de la variable à étudier se regroupent géographiquement : **des lieux proches sont plus différents que des lieux éloignés.** On retrouve généralement ce type de situation en présence de **concurrence spatiale.**
- En l'absence d'autocorrélation spatiale, on peut considérer que la répartition spatiale des observations est **aléatoire.**

V. L'autocorrélation spatiale



Le regroupement spatial des valeurs similaires est-il significatif?

Dans quelle mesure aurait-il pu être observé si les observations étaient réparties spatialement de façon aléatoire?

V. L'autocorrélation spatiale

Objectifs des indices d'autocorrélation spatiale

- Evaluer la **dépendance spatiale** entre les valeurs d'une même variable en différents endroits de l'espace
- tester la **significativité** de la structure spatiale identifiée.

Deux critères

- la **proximité** spatiale ;
- la **ressemblance ou la dissemblance** des valeurs de la variable pour les unités spatiales considérées.

Attention : si les données sont agrégées suivant un découpage qui ne respecte pas le phénomène sous-jacent, on surestimera ou sous-estimera la force du lien spatial.

V. L'autocorrélation spatiale



LE DIAGRAMME DE MORAN

- Le diagramme de Moran permet une lecture rapide de la structure spatiale.

Construction


- y centrée en abscisse
- $W*y$ en ordonnée (où W est la matrice de poids normalisée)
- Les deux propriétés y centrée et W normalisée impliquent que la moyenne empirique de Wy est égale à celle de y et donc à 0.
- On trace également la droite de régression linéaire de Wy en fonction de y et les droites d'équation $y = 0$ et $Wy = 0$ qui délimitent des quadrants.

V. L'autocorrélation spatiale




V. L'autocorrélation spatiale

- En haut à droite (quadrant 1) valeurs de la variable plus élevées que la moyenne, dans un voisinage qui leur ressemble (autocorrélation spatiale positive et valeur de l'indice élevé ; **structure high-high**).
- En bas à gauche (quadrant 3), valeurs de la variable plus faibles que la moyenne, dans un voisinage qui leur ressemble (autocorrélation spatiale positive et valeur de l'indice faible ; **structure low-low**).



V. L'autocorrélation spatiale

- En bas à droite (quadrant 2) ont des valeurs de la variable plus élevées que la moyenne dans un voisinage qui ne leur ressemble pas (autocorrélation spatiale négative et valeur de l'indice élevé ; **structure high-low**).
- En haut à gauche (quadrant 4), valeurs de la variable plus basses que la moyenne dans un voisinage qui ne leur ressemble pas (autocorrélation spatiale négative et valeur de l'indice faible ; **structure low-high**).



V. L'autocorrélation spatiale

- Lorsque le diagramme de Moran met en avant une structure spatiale particulière, **le calcul des indices d'autocorrélation spatiale** a pour objectif de répondre à deux questions :
- Les valeurs prises par les observations voisines **auraient-elles pu être aussi comparables (ou aussi dissemblables) par le simple fait du hasard ?**
- Si tel n'est pas le cas, **il y a de l'autocorrélation spatiale** : quels en sont le signe et la force ?
- Répondre à la première question revient à **tester l'hypothèse d'absence d'autocorrélation spatiale** pour une variable brute y .
 - H_0 : absence d'autocorrélation spatiale
 - H_1 : présence d'autocorrélation spatiale

V. L'autocorrélation spatiale

- L'inférence sur le I de Moran est généralement menée sous **l'hypothèse de randomisation**.
 - L'estimation de la statistique obtenue à partir des données est comparée avec la distribution de celle obtenue en réordonnant au hasard (permutations) les données.
 - L'idée est simplement que si l'hypothèse nulle est vraie, alors toutes les combinaisons possibles des données sont équiprobables.
 - Les données observées sont alors seulement l'une des réalisations parmi toutes celles également possibles.

V. L'autocorrélation spatiale

- De manière très générale, les indices d'autocorrélation spatiale permettent de caractériser la corrélation entre les mesures géographiquement voisines d'un phénomène mesuré.
- Si l'on désigne par WY le vecteur des moyennes de la variable Y (où W désigne la matrice de pondération) dans le voisinage de chaque unité spatiale, les indices d'autocorrélation spatiale se mettent sous la forme :

$$Corr(Y, WY) = \frac{Cov(Y, WY)}{\sqrt{Var(Y) \cdot Var(WY)}}$$

V. L'autocorrélation spatiale

L'indice de Geary

- Il se calcule de la manière suivante :

$$c_W = \frac{n-1}{2 \sum_i \sum_j w_{ij}} \frac{\sum_i \sum_j w_{ij} (y_i - y_j)^2}{\sum_i (y_i - \bar{y})^2} \quad i \neq j$$

- Sous H_0 : les différences entre voisins n'ont PAS de structure particulière (= ABSENCE d'autocorrélation spatiale) $\rightarrow c_W \approx 1$
- Si $c_W < 1$ (après test de significativité) : autocorrélation spatiale positive = les valeurs similaires sont proches spatialement.

V. L'autocorrélation spatiale

L'indice de Moran

- Il se calcule de la manière suivante :

$$I_W = \frac{n}{\sum_i \sum_j w_{ij}} \frac{\sum_i \sum_j w_{ij} (y_i - \bar{y})(y_j - \bar{y})}{\sum_i (y_i - \bar{y})^2} \quad i \neq j$$

- Sous H_0 : les voisins ne co-varient PAS d'une façon particulière (= ABSENCE d'autocorrélation spatiale) $\rightarrow I_W \approx 0$
- Si $I_W > 0$ (après test de significativité) : autocorrélation spatiale positive = les valeurs similaires sont proches spatialement.

- Asymptotiquement $\frac{I_W - \mathbb{E}(I_W)}{\sqrt{\text{Var}(I_W)}} \sim \mathcal{N}(0, 1)$

V. L'autocorrélation spatiale

Limites de l'indicateur global :

- Les statistiques globales font **l'hypothèse de stationnarité** du processus spatial : **l'autocorrélation spatiale serait la même dans tout l'espace.**
- Cette hypothèse est d'autant moins réaliste que le nombre d'observations est élevé.

V. L'autocorrélation spatiale

Objectifs d'un indicateur local :

- Détecter les regroupements significatifs de valeurs identiques autour d'une **localisation particulière** (clusters).
- Repérer des **zones de non-stationnarité spatiale**, qui ne suivent pas le processus global.

V. L'autocorrélation spatiale

LISA : Local Indicator of Spatial Association

Définition (Anselin, 1995)

- **Pour chaque observation**, ils indiquent l'intensité du regroupement de valeurs similaires (ou de tendance opposée) autour de cette observation.
- La somme des indices locaux sur l'ensemble des observations est **proportionnelle** à l'indice global correspondant.

I de Moran Local :

$$l_i = (y_i - \bar{y}) \sum_j w_{ij} (y_j - \bar{y})$$


$$l_W = \text{constante} * \sum_i l_i$$

V. L'autocorrélation spatiale

Application sur les revenus médians à Paris (à l'échelle de l'IRIS) :

$I_i > 0$ indique un regroupement de valeurs similaires (plus élevées ou plus faibles que la moyenne).


$I_j < 0$ indique un regroupement de valeurs dissimilaires (par exemple des valeurs élevées entourées de valeurs faibles)



V. L'autocorrélation spatiale



- Des LISA **significatifs** correspondent à des regroupements de valeurs **similaires ou dissimilaires plus marqués que ce que l'on aurait pu observer à partir d'une répartition spatiale aléatoire.**
- Ces regroupements peuvent correspondre aux quatre types de regroupements spatiaux identifiables sur le **diagramme de Moran** (high-high, low-low, high-low ou low-low).
- Le **test de significativité de chaque LISA** repose sur une statistique supposée suivre asymptotiquement une loi normale sous l'hypothèse nulle.

V. L'autocorrélation spatiale



I de Moran locaux significatifs

■ Revenus élevés entourés de revenus élevés High - High
■ n.s.
■ Revenus faibles entourés de revenus faibles Low - Low



V. L'autocorrélation spatiale

CONCLUSION

- Si de l'autocorrélation est détectée, alors il faudra **s'interroger sur son modèle économétrique (cf. cours 3A)**, notamment :
- **Si dépendance spatiale** : les valeurs des observations sont **corrélées dans l'espace** -> **économétrie spatiale**.
- **Si hétérogénéité spatiale** : instabilité structurelle, **les variables explicatives n'ont pas partout la même influence sur la variable dépendante** -> **régression géographiquement pondérée**.
- Problème : ces deux phénomènes sont rarement « purs » ...

V. L'autocorrélation spatiale

CONCLUSION

- Ce chapitre ne traite pas des données ponctuelles (comparaison à une répartition de points aléatoire : K de Ripley, Duranton, etc...)
- Ni des données continues (variogramme et krigeage avec étude de portée)
- **Voir 3^e année!**